

SegBAM : Unet with spatial attention mechanisms

Ahmed Ashraf Shalabi
Department of Computer Engineering
Sivas Cumhuriyet University
aceshalabi@gmail.com

Danışman: Doç.Dr.Kemal ADEM
Department of Computer Engineering
Sivas Cumhuriyet University
kemaladem@cumhuriyet.edu.tr

June 10, 2025

Özet

Semantik segmentasyon, bilgisayarlı görmenin temel görevlerinden biridir ve otonom sürüş sistemleri, tıbbi görüntüleme ve robotik gibi çok çeşitli gerçek dünya uygulamalarında hayati bir rol oynamaktadır. Bu görev, bir görüntüdeki her piksele bir sınıf etiketi atayarak, makinenin sahneyi ayrıntılı bir düzeyde anlamasını sağlar. Derin öğrenmeye dayalı çeşitli mimariler arasında, encoder-decoder tabanlı modeller —özellikle U-Net— hiyerarşik özellikler çıkarma ve ayrıntılı mekânsal haritaları yeniden oluşturma yetenekleri nedeniyle yaygın olarak kullanılmaktadır. Ancak bu modeller, özellikle karmaşık sahnelerde, ince mekânsal bağıntıları ve bağlamsal bilgileri yakalamada bazı zorluklarla karşılaşmaktadır.

Bu çalışmada, klasik U-Net mimarisini geliştirmek amacıyla, modele Convolutional Block Attention Module (CBAM) ve residual blokları entegre ettik. CBAM, kanal ve mekânsal dikkat mekanizmaları aracılığıyla modelin daha bilgilendirici özelliklere odaklanmasını sağlarken, residual bloklar ise daha derin ağlarda gradyan akışını iyileştirerek öğrenmeyi kolaylaştırır. Yöntemimizin etkinliğini değerlendirmek amacıyla, farklı stiller, pozlar ve giysi türleri içeren insan kıyafetlerinin segmentasyonu ve etiketlenmesine yönelik özel bir veri kümesi üzerinde deneyler gerçekleştirdik.

Deneysel sonuçlarımız, temel U-Net modelleriyle karşılaştırıldığında, kayıp, piksel doğruluğu ve IoU (Intersection over Union) gibi önemli değerlendirme metriklerinde tutarlı iyileşmeler göstermiştir. Bu bulgular, dikkat mekanizmaları ve residual öğrenmenin modelin doğru segmentasyon yapma yeteneğini önemli ölçüde artırdığını göstermektedir. Genel olarak bu çalışma, mimari iyileştirmelerin bir arada kullanılmasının semantik segmentasyon performansını geliştirmedeki potansiyelini ortaya koymakta ve daha karmaşık ve derin modellerle yapılacak gelecekteki araştırmalar için teşvik edici niteliktedir.

1 Giriş

Anlamsal segmentasyon görevi basitçe, bir görüntüdeki her pikseli ilgi duyulan bir sınıfa göre sınıflandırmak olarak tanımlayabiliriz. Örneğin, otonom araçlarda görüntüdeki pikselleri yayalar, araçlar, yollar gibi sınıflara ayırırız. Bu alanda birçok ilerleme kaydedilmiştir. Semantik segmentasyon görevinde devrim yaratan ilk mimari, bilgisayarlı görü alanında encoder (kodlayıcı) ve decoder (çözücü) model fikrini sunan U-Net makalesi [4] olmuştur. Encoder ve decoder mimarisi, SegNet [1], DeepLabv3+ [2] ve SegFormer [7] çalışmalarında sunulduğu üzere, semantik segmentasyon alanında bir standart hâline gelmiştir. Bu çalışmada, klasik U-Net

mimarisiyle değil, onun geliştirilmiş bir versiyonuyla deneyler yaptık. Ayrıca, CBAM makalesinde [6] sunulan mekânsal dikkat (spatial attention) modülünü de mimariye ekledik. Bunun yanında, ResNet makalesinde [3] tanıtılan residual blokları kullanarak da çeşitli deneyler gerçekleştirdik.

- Katkı** 1. U-Net mimarisine CBAM modülleri eklemenin etkisini inceliyoruz.
2. [Dataset] üzerinde elde edilen performansı raporluyor ve mimari seçimlere dair içgörüler sunuyoruz.

2 İlgili Çalışmalar

2.1 Unet architecture

U-Net mimarisini inceledik; bu mimari basitçe iki bileşenden oluşur: encoder (kodlayıcı) ve decoder (çözücü). Encoder, birden fazla CNN katmanından oluşur ve bu katmanlar, daha sonra decoder tarafından kullanılacak bir özellik haritası (feature map) üretir. Encoder, özellik haritasını ürettikten sonra, bu haritanın bir kopyasını alır ve pooling işlemi uygular; bu kopya, encoder'daki bir sonraki katmana iletilir. Genellikle kullanılan pooling işlemi 2x2 boyutundadır, yani her seferinde özellik haritası bir öncekinin yarı boyutuna indirilir.

2.2 residual block

ResNet makalesinin [3] ele aldığı problem, model derinleştikçe eğitimin zorlaşmasıdır. Bu sorunu çözmek için, makalede skip connection (atlamalı bağlantı) önerilmiştir Şekil 1a'de . Bu yöntem, bir katmandan elde edilen özelliklerin (feature'ların), işlemden sonraki katmana tekrar eklenmesi şeklinde çalışır.

Makalede iki farklı residual blok sunulmuştur:


- Normal residual block
- Bottleneck residual block, ki bu yapı, normal bloğa göre daha verimli ve daha başarılı performans göstermektedir.

2.3 CBAM Module


CBAM modülü (blok), [6] kaynağında sunulduğu üzere, konvolüsyonel dikkat (attention) bloğudur ve iki alt bloktan oluşur: kanal dikkat (channel attention) ve mekânsal dikkat (spatial attention). Bu bloklar, şekil 1b'de gösterildiği gibi ardışık olarak uygulanmaktadır. Bu işlem, verilen bir özellik haritasının $F \in \mathbb{R}^{C \times H \times W}$ alınmasıyla başlar; bu harita önce kanal dikkat bloğuna $M_c \in \mathbb{R}^{C \times 1 \times 1}$ verilir, ardından elde edilen çıktı mekânsal dikkat bloğuna $M_s \in \mathbb{R}^{1 \times H \times W}$ beslenir. Bu sembol $\otimes$, eleman bazında çarpma (element-wise multiplication) anlamına gelir.

$$\begin{aligned} F' &= M_c(F) \otimes F, \\ F'' &= M_s(F') \otimes F' \end{aligned}$$

kanal dikkat bu bloğu, verilen özellik haritası $F \in \mathbb{R}^{C \times H \times W}$ üzerinde maksimum havuzlama (max pooling) ve ortalama havuzlama (average pooling) işlemleri uygular. Bu işlemlerden elde edilen çıktılar, ortak bir çok katmanlı algılayıcı (MLP) üzerinden geçirilir. Daha sonra bu iki çıktı toplanarak, kanal dikkat haritası $F \in \mathbb{R}^{C \times 1 \times 1}$ elde edilir. Son olarak, bu dikkat haritası F ile çarpılarak (element-wise) sonuç F' üretilir ve ardından bir sigmoid aktivasyon fonksiyonu uygulanır. Bu blok aşağıdaki şekil 2a'de gösterilmiştir.



(a) residual learning : building block



(b) Konvolüsyonel Blok Dikkat Modülü

Figure 1

mekânsal dikkat Bu blok, kanal dikkat mekanizması tarafından üretilen F' özellik haritasını alır. Ardından, kanal boyutunda maksimum havuzlama (max pooling) ve ortalama havuzlama (avg pooling) işlemleri uygulanır. Bu iki çıktı, standart bir konvolüsyon işlemi ile işlenir; bu işlemde $f^{7 \times 7}$ boyutunda bir filtre kullanılır ve ardından bir sigmoid aktivasyon fonksiyonu uygulanır. Bu blok aşağıdaki şekil 2b'de gösterilmiştir.

3 Yöntem


3.1 Veri Kümesi

Bu veri seti, insan kıyafetlerinin segmentasyonu ve etiketlenmesi [8] ile ilgilidir ve CVPR 2014 konferansında sunulmuştur. Veri seti, 59 farklı sınıf veya etiket içeren 1000 adet anotasyonlu fotoğraf barındırmaktadır. Geniş bir yelpazede stil, aksesuar, giysi ve poz çeşitliliği içermektedir.


3.2 Model ve Algoritmalar

loss function Bu çalışmada, özel bir kayıp fonksiyonu olarak Dice Loss fonksiyonu kullanılmıştır; bu fonksiyon, [5] kaynağında önerilmiştir. Bu fonksiyon, sınıflar arasındaki yüksek dengesizliği azaltmak amacıyla geliştirilmiştir.

Ayrıca, [4] kaynağında kullanılan WCE (Ağırlıklı Çapraz Entropi) yöntemiyle karşılaştırılmıştır. Yapılan karşılaştırmalarda, yüksek sınıf dengesizliğine sahip veri setleri için Dice Loss'un daha iyi sonuçlar gösterilmiştir.



(a) kanal dikkat bloğu



(b) mekânsal dikkat bloğu

Figure 2

Makale içerisinde, biri ikili sınıf segmentasyonu için, diğeri ise çoklu sınıf segmentasyonu için daha genel olan iki farklı varyant sunmuşlardır.

Dice Loss'un ikili (binary) versiyonu aşağıda gösterilmiştir :

$$DL_2 = 1 - \frac{\sum_{n=1}^N p_n r_n + \epsilon}{\sum_{n=1}^N p_n + r_n + \epsilon} - \frac{\sum_{n=1}^N (1 - p_n)(1 - r_n) + \epsilon}{\sum_{n=1}^N 1 - p_n - r_n + \epsilon} \quad (1)$$

Dice Loss'un çoklu sınıf versiyonu aşağıda sunulmuştur :

$$GDL = 1 - 2 \frac{\sum_{l=1}^2 w_l \sum_{n=1}^2 r_{ln} p_{ln}}{\sum_{l=1}^2 w_l r_{ln} + p_{ln}} \quad (2)$$

Verimiz yüksek derecede dengesiz olduğundan, çalışmamızda GDL (Generalized Dice Loss) fonksiyonunu kullandık.

experimental design Beş farklı U-Net mimarisi varyantı oluşturduk: ilki, [4] kaynağında sunulan **klasik U-Net mimarisi** gibidir. İkinci varyantta, katmanlar arasında **residual bloklar** kullandık. Diğer üç varyantta ise, [6] kaynağında önerilen **CBAM modülünü** kullandık; bu modül tarafından üretilen **özellik haritaları**, **decoder çıkış katmanlarına** şekil 3'de **birleştirilerek (concatenate edilerek)** eklenmiştir.




Figure 3: Unet model with CBAM Module

3.3 deneysel ayarlar

Verisetimizi [8] üç parçaya ayırdık: eğitim seti %75, doğrulama seti %15 ve test seti %10. Eğitim ve doğrulama setleri eğitim sürecinde kullanılırken, test seti karşılaştırmalar için kullanılmıştır. Veriyi bu şekilde ayırmamızın nedeni, modeller arasında örneklerin tutarlılığını sağlamaktır. Her modeli 50 epoch boyunca eğittik ve erken durdurma (early stopping) ekledik; yani, eğer doğrulama kaybı (validation loss) art arda 5 epoch boyunca önceki en düşük değerden daha düşük olmazsa, eğitim durdurulmaktadır. Modeller performansları, piksel doğruluğu (pixel accuracy) ve Kesişim/Birleşim (Intersection over Union - IoU) metrikleri kullanılarak değerlendirilmiştir. Öğrenme oranı olarak 9^{-4} kullandık. Batch size 16 idi ve görüntüleri 640x360 piksele yeniden boyutlandırdık. Optimizasyon için Adam algoritmasını kullandık. Deneyleri gerçekleştirmek için PyTorch kullandık.

4 Deneyler ve Sonuçlar

İlk olarak, klasik U-Net ve artık blok (residual block) kullanılan U-Net ile elde edilen sonuçları aşağıdaki şekil 4’de sunuyoruz. Bunun ardından, şekil 5’de gösterildiği üzere CBAM içeren U-Net varyantları üzerinde deneyler gerçekleştirdik. Modelleri eğittikten sonra test veri seti üzerinde de değerlendirdik ve CBAM içeren modellerin, özellikle IoU metriğinde, CBAM içermeyen modellere kıyasla hafif bir üstünlük sağladığını gözlemledik; bu durum Tablo 1’de gösterilmiştir.

Table 1: results against test set

modeller	loss	pixel accurecy	IOU
classic Unet	0.813	99.4	70
residual Unet	0.814	99.4	71
classic Unet w/ cbam	0.8	99	70
residual Unet w/cbam	0.78	99.5	71.5
dropout Unet w/ cbam	0.8	99.5	71




Figure 4: Bu şekilde, klasik ve artık (residual) U-Net modelleri üzerinde yapılan deneyleri üç metrik (kayıp, piksel doğruluğu ve IoU) üzerinden göstermekteyiz. Noktalı çizgi, doğrulama (validation) setine aittir.




Figure 5: CBAM modüllerine sahip U-Net modeli; noktalı çizgiler doğrulama verisini göstermektedir.

5 Sonuç ve Gelecek Çalışmalar

Yukarıdaki tablo ve şekillerden, CBAM modelli modellerin, CBAM içermeyen varyantlara kıyasla biraz daha iyi bir performans sergilediği söylenebilir; bu durum, ilgili makalede görüntü sınıflandırma görevi üzerine sunulan performansla da örtüşmektedir. CBAM modüllerinin daha derin modellerde daha iyi performans gösterebileceğini düşünmekteyiz. Bizim çalışmamızda 4 blok kullanılırken, ilgili çalışmada CBAM, 50 katmanlı ResNet modeli üzerinde uygulanmıştır. Bu çalışmada CBAM modüllerini inceledik ve bu modülleri segmentasyon üzerindeki etkisini görmek amacıyla U-Net modelleriyle birlikte kullandık. CBAM modüllerinin, klasik U-Net modellerine kıyasla hafif bir performans artışı sağladığını gözlemledik. Daha derin modellerde daha iyi sonuçlar verebileceğini düşünmekteyiz. Gelecek çalışmalar için, CBAM modüllerinin SegNet [1], DeepLabV3+ [2] ve SegFormer [7] gibi diğer encoder-decoder mimarileriyle eğitilmesinin faydalı olabileceğini önermekteyiz.

6 references

References

- [1] Vijay Badrinarayanan, Alex Kendall, and Roberto Cipolla. Segnet: A deep convolutional encoder-decoder architecture for image segmentation, 2016.
- [2] Liang-Chieh Chen, Yukun Zhu, George Papandreou, Florian Schroff, and Hartwig Adam. Encoder-decoder with atrous separable convolution for semantic image segmentation, 2018.
- [3] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2016.
- [4] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation, 2015.
- [5] Carole H. Sudre, Wenqi Li, Tom Vercauteren, Sebastien Ourselin, and M. Jorge Cardoso. *Generalised Dice Overlap as a Deep Learning Loss Function for Highly Unbalanced Segmentations*, page 240–248. Springer International Publishing, 2017.
- [6] Sanghyun Woo, Jongchan Park, Joon-Young Lee, and In So Kweon. Cbam: Convolutional block attention module, 2018.
- [7] Enze Xie, Wenhai Wang, Zhiding Yu, Anima Anandkumar, Jose M. Alvarez, and Ping Luo. Segformer: Simple and efficient design for semantic segmentation with transformers, 2021.
- [8] Wei Yang, Ping Luo, and Liang Lin. Clothing co-parsing by joint image segmentation and labeling. In *Computer Vision and Pattern Recognition (CVPR), 2014 IEEE Conference on*. IEEE, 2013.